

Спарсификация UNet

magnitude / 2:4 / structured + fine-tune

Курилов Олег

Эффективные модели ML и архитектуры нейросетей

Апрель 2026

Три метода и главные вопросы

Что мерим


- **Magnitude (L1)** --- занулить нижние $N\%$ весов по $|w|$
- **2:4 semi-structured** --- 2 из 4 нулей вдоль input-channel
- **Structured channel** --- зануляем целые out-каналы

На что смотрим


- Качество --- Dice
- Скорость --- ms/img
- Память --- peak GB
- Восстановимо ли через fine-tune?

Бенчмарк: UNet 31 M, Carvana val (400 images), A4000 16 GB, fp16, bs=8.


Качество vs sparsity (без fine-tune)




Fine-tune возвращает (и превышает) baseline



Iterative ladder и полный NVIDIA ASP combo



Gradual ladder 30% → 50% → 70% даёт **Dice 0.9950** vs one-shot 0.9940 --- **+0.001**.




Полный ASP recipe: magnitude → 2:4 → fine-tune. Decoder Dice 0.9912 → 0.9944 при 24% глобальной sparsity.

Реальный speedup: profiler и cuSPARSELt

PyTorch Profiler (4 активных батча):

Конфиг	Self CUDA total
baseline_fp16	1.085 s
magnitude@0.5	1.078 s
2:4 (50%)	1.076 s

Разница < 1% --- 95% времени в `aten::conv2d`. Dense fp16 cudnn kernels не используют нули.




cuSPARSELt на A4000 не даёт speedup даже на LLM-shape.

Hardware 2:4 path работает только на datacenter Ampere (sm_80: A100).

Method landscape и выводы

Method landscape — Dice vs sparsity, with and without fine-tune



Что узнали:

- Качество --- 70% magnitude бесплатно, через retrain --- выше baseline
- Скорость --- 0% на dense kernels, отрицательная на cuSPARSELt
- Память --- идентична (zeros внутри tensor занимают то же место)
- Сэкономим только размер чекпоинта в sparse-формате

Что дальше:

- Physical channel removal (torch_pruning)
- Перенос на A100 → cuSPARSELt включится

- PR: github.com/algorithm-pirogok/effml_unet_check/pull/1
- Полный отчёт: [docs/sparsity.md](#) (200+ строк)
- 9 JSON: full benchmark, finetune, iterative, asp, cusparselt, memory, profile, smoke
- 6 фигур + 3 chrome traces (ui.perfetto.dev)

Вопросы?